

Informe Proyecto AutoTec

Sector Automotriz

<https://github.com/IICG-Coquimbo/proyecto-big-data-2026-autotec.git>

Asignatura

Big Data para la toma de decisiones

Fecha

24-05-2026

Integrantes

Belén Andrades

Luz Azocar

Daniela Cofré

Neiel Cortés

Jocelyn León

Javiera Pizarro

Martin Rojas

Índice

1. Situación Problema	2
1.1. Hallazgo principal tras el análisis	2
1.2. Tratamiento de Veracidad	2
1.3. Ingeniería de Atributos	2
2. Análisis Descriptivo (EDA)	3
2.1. Análisis Multivariado	3
2.2. Interpretación	8
3. Segmentación mediante Clustering	8
3.1. Objetivo de la Segmentación	8
3.2. Selección y Justificación del Algoritmo	8
3.3. Validación Técnica: Método del Codo	9
3.4. Visualización de Clústeres mediante PCA	10
3.5. Perfilamiento de Clústeres	10
3.6. Interpretación de Negocio	11
3.7. Interpretación de DBSCAN	11
3.8. Validación Técnica: Silhouette Score	12
3.9. Relación con la Depreciación Vehicular	13
4. Definición Predictiva y Meta-Datos	13
4.1. Variable Dependiente (Y)	13
4.2. Factibilidad del Modelo Supervisado	14
4.3. Selección del Modelo Predictivo	14
5. Conclusión	15
6. Anexo: Tabla de Aporte Individual	15

1. Situación Problema

Las organizaciones del sector automotriz enfrentan dificultades para definir precios y tasaciones de vehículos usados debido al uso de métodos manuales. La valoración suele basarse en experiencia o referencias generales, sin considerar adecuadamente variables clave como la marca, modelo, año y el kilometraje del vehículo. Esto genera tasaciones imprecisas, provocando riesgos de sobrevaloración o subvaloración, afectando tanto la competitividad como la rentabilidad de las organizaciones.

1.1. Hallazgo principal tras el análisis

- **Kilometraje y antigüedad deprecian el precio de forma considerable.** A mayor kilometraje y más años de antigüedad, menor valor de mercado. Ambas variables actúan en conjunto y son los principales factores que influyen en el precio.
- **La marca disminuye el impacto del kilometraje.** Un mismo kilometraje deprecia más a una marca general que a una premium.
- **Tres segmentos de riesgo claramente diferenciados.** Vehículos con más de 8 años o más de 120.000 km caen en el segmento de alta depreciación, donde las tasaciones manuales tienen mayor probabilidad de error.
- **La geografía es secundaria.** Las diferencias de precio entre ciudades reflejan el tipo de autos disponibles en cada zona, no una depreciación diferencial real.

En conclusión, el kilometraje no opera solo, su repercusión en el precio depende de la antigüedad y la marca del vehículo.

1.2. Tratamiento de Veracidad

Se eliminan principalmente registros con datos inválidos generados durante el proceso de scraping. En variables categóricas, se detectaron valores fuera del dominio esperado, como lo eran “poco kilometraje”, “único dueño”, etc. Estas inconsistencias se originan debido a que el proceso de extracción capturaba etiquetas promocionales presentes en las imágenes o publicaciones de los automóviles, interpretándose erróneamente como atributos del vehículo. Esto provoca contaminación e inconsistencias en la base de datos, afectando la calidad y confiabilidad de la información recopilada.

1.3. Ingeniería de Atributos

Se decidieron agregar seis variables nuevas, las cuales se detallan a continuación:

- **tipo_marca:** separa las marcas premium de las generalistas.
- **antigüedad_auto:** nos muestra los años de uso que posee el automóvil.
- **rango_kilometraje:** nos categoriza el kilometraje del vehículo como “Bajo”, “Medio” o “Alto” según parámetros establecidos.

- **uso_anual_estimado:** esta variable devuelve el promedio anual de kilometraje por los años de uso del vehículo.
- **es_ecologico:** en esta variable se indica si el automóvil es o no ecológico. La condición para que lo sea es que sea híbrido o eléctrico.
- **categoria_precio:** muestra si el valor del vehículo es “Bajo”, “Medio” o “Alto” según parámetros establecidos.

2. Análisis Descriptivo (EDA)

El análisis exploratorio de datos, conocido como EDA, se desarrolló con el propósito de comprender el comportamiento general de la base de datos del proyecto AutoTec. Para ello, se consideraron variables originales como marca, modelo, precio, kilometraje, año, combustible y ciudad, ya que estas representan las principales características que influyen en el valor comercial de un vehículo usado.

Además de estas variables iniciales, se construyeron variables derivadas que permiten realizar un análisis más completo. Estas nuevas variables ayudan a observar patrones que no siempre son evidentes al analizar los datos de forma individual.

La finalidad de este análisis es identificar cómo se relacionan las características técnicas y comerciales de los vehículos con su precio de mercado. De esta manera, el EDA permite obtener una visión más clara sobre qué factores pueden aumentar o disminuir el valor de un automóvil, dejando una base analítica útil para futuras etapas de modelamiento predictivo.

2.1. Análisis Multivariado

El análisis se desarrolló sobre una base de 1.988 registros válidos, considerando las variables precio, kilometraje, año, antigüedad, marca, ciudad y combustible, junto con las variables derivadas construidas en la etapa de ingeniería de atributos.

Estadísticas descriptivas generales

	summary	precio	kilometraje	year	antigüedad_auto	uso_anual_estimado
0	Cantidad de registros	1.988	1.988	1.988	1.988	1.988
1	Promedio	16.450.599	71.070	2021	5	17.156
2	Desviación estándar	9.970.242	49.937	3	4	10.589
3	Valor mínimo	2.055.000	1.000	1991	0	706
4	Valor máximo	104.990.000	300.000	2026	35	180.000

Figura 1: Estadísticas descriptivas generales

Matriz de correlaciones

Se construyó una matriz de correlaciones entre las variables numéricas principales, obteniendo los siguientes resultados:

- **Precio y Año:** correlación positiva de +0.236. Los vehículos más recientes conservan mayor valor comercial.
- **Precio y Kilometraje:** correlación negativa de -0.233. A mayor kilometraje, menor precio de mercado.
- **Kilometraje y Año:** correlación negativa de -0.700. Los vehículos más antiguos acumulan significativamente mayor kilometraje.
- **Antigüedad y Año:** correlación perfecta negativa de -1.000, ya que son variables inversamente construidas.




Figura 2: Matriz de correlaciones

Visualización de relaciones mediante Pairplot

El pairplot permite observar simultáneamente las relaciones entre precio, kilometraje y año, diferenciando entre marcas premium y generalistas. Se evidencia que las marcas premium, en rojo, tienden a concentrarse en rangos de precio más altos con menor kilometraje, mientras que las marcas generalistas, en azul, presentan mayor dispersión en ambas variables. La distribución en la diagonal muestra que el precio de las marcas premium tiene una distribución más dispersa y con valores más elevados respecto a las generalistas.




Figura 3: Visualización de relaciones mediante pairplot

Relaciones entre variables

El análisis de dispersión muestra las correlaciones identificadas. La relación Precio vs Kilometraje muestra una tendencia descendente clara: los vehículos con más de 120.000 km presentan precios notoriamente menores que aquellos con bajo uso. La relación Precio vs Año evidencia que los vehículos fabricados antes de 2014 concentran los precios más bajos del mercado. La relación Kilometraje vs Año muestra que los autos más antiguos tienden a acumular mayor desgaste acumulado.




Figura 4: Relaciones entre variables

Análisis multivariado

Precio + Año + Kilometraje: el gráfico de dispersión evidencia visualmente que los

vehículos más recientes, desde 2020 en adelante, concentran los precios más altos, con valores que superan los \$40M. A su vez, el color de los puntos evidencia que los vehículos con mayor kilometraje, tonos rojizos sobre 150.000 km, se ubican principalmente en los rangos de precio más bajos, reforzando la relación entre kilometraje y depreciación.

Precio por Marca: cabe destacar que en este top 10 predominan marcas generalistas, lo que explica la concentración de precios entre \$10M y \$20M. Las marcas premium como BMW, Audi y Mercedes, aunque con precios notoriamente más altos, no alcanzan el volumen necesario para aparecer en este ranking, lo cual es consistente con uno de los hallazgos del proyecto: la marca disminuye el impacto del kilometraje en la depreciación.

Precio por Ciudad: las 8 ciudades con mayor presencia en el dataset muestran precios medianos relativamente similares, oscilando entre \$10M y \$17M. San Joaquín presenta el precio mediano más alto, mientras que Cerrillos y Puerto Montt se ubican en los valores más bajos. Esta baja variabilidad entre ciudades confirma que la geografía es un factor secundario que refleja el tipo de vehículos disponibles en cada zona, más que una depreciación diferencial real asociada a la ubicación.

Precio por Combustible: se observan diferencias significativas según el tipo de combustible. Los vehículos eléctricos/híbridos presentan el precio mediano dentro del conjunto analizado, posiblemente asociado a su posicionamiento en el mercado y menor antigüedad promedio. Los vehículos diésel se ubican en un rango intermedio, mientras que los de bencina registran el precio mediano más bajo. Esta diferencia es coherente con la clasificación ecológica incorporada en la ingeniería de atributos: los vehículos eléctricos e híbridos tienen menor desgaste por uso y mayor valor comercial en el mercado actual.




Figura 5: Análisis multivariado

Boxplots: los boxplots visualizan que las marcas premium tienen mayor variabilidad de precio, con valores extremos muy por encima del mercado general. Los vehículos en el rango de kilometraje “Alto” concentran precios más bajos y menor variabilidad, siendo consistentes con el Clúster 1, correspondiente a mayor depreciación y kilometraje promedio de 140.042 km.




Figura 6: Boxplots de precios y kilometraje

Detección de anomalías: mediante el método IQR se detectaron los siguientes registros atípicos:

- **Precio:** 126 anomalías, equivalentes al 6.34 %, con límite superior en \$33.678.750, pudiendo ser principalmente vehículos de lujo con precios muy por encima del mercado general.
- **Kilometraje:** 49 anomalías, equivalentes al 2.46 %, con límite superior en 198.777 km. Pueden corresponder a vehículos de trabajo con uso intensivo.
- **Año:** 81 anomalías, equivalentes al 4.07 %, correspondientes a vehículos fabricados antes de 2014, considerados outliers por antigüedad dentro del conjunto de datos.

Estos resultados son consistentes con la presencia de un número reducido de puntos de ruido detectados por DBSCAN, lo que sugiere que la mayoría de las observaciones sigue una estructura general clara, aunque con casos extremos que deben analizarse por separado.




Figura 7: Detección de anomalías

2.2. Interpretación

El análisis descriptivo multivariado permite concluir que la depreciación de los vehículos usados responde a una combinación de factores que actúan en conjunto.

Las correlaciones identificadas confirman que el kilometraje y la antigüedad son los principales factores asociados a una mayor depreciación. Sin embargo, estos factores no operan de forma aislada; la marca del vehículo introduce diferencias importantes en el precio, incluso entre vehículos con niveles similares de uso, lo que refuerza el carácter multivariable de la depreciación vehicular.

La detección de anomalías valida además que el conjunto de datos posee una estructura adecuada para futuras etapas de modelado predictivo, con un porcentaje reducido de observaciones atípicas que no comprometen la asertividad del análisis.

3. Segmentación mediante Clustering

3.1. Objetivo de la Segmentación

El objetivo de esta etapa es identificar segmentos de vehículos con características similares mediante técnicas de aprendizaje no supervisado.

La segmentación permite comprender mejor el comportamiento del mercado de vehículos usados y analizar patrones de depreciación considerando variables relevantes como precio, kilometraje, año de fabricación, marca y modelo del vehículo.

Los resultados obtenidos permitieron identificar grupos diferenciados de vehículos con distintos niveles de depreciación, valor comercial y características de mercado. Esta segmentación constituye una base para futuras etapas de modelado predictivo y aporta evidencia sobre cómo factores mecánicos y comerciales influyen conjuntamente en el comportamiento del precio de vehículos usados.

3.2. Selección y Justificación del Algoritmo

Durante el desarrollo del proyecto se evaluaron distintas técnicas de clustering, principalmente K-Means y DBSCAN, con el objetivo de identificar segmentos de vehículos usados según su comportamiento de depreciación.

Tras analizar los resultados obtenidos y comparar ambas alternativas, se seleccionó K-Means como algoritmo principal debido a su capacidad para generar grupos claramente diferenciados, interpretables y útiles desde una perspectiva comercial.

- **Variables iniciales:** precio, kilometraje y año de fabricación.
- **Variables adicionales:** cat_marca y cat_modelo, para capturar diferencias asociadas al posicionamiento comercial y valor de mercado.
- **Variable descartada:** cat_combustible, ya que redujo la calidad del agrupamiento.

La validación técnica se realizó mediante el Método del Codo y el Índice Silhouette. Por

otro lado, DBSCAN fue utilizado como técnica complementaria para detectar observaciones atípicas y apoyar la validación de la estructura general de los datos.




Figura 8: Distribución espacial de vehículos mediante PCA

3.3. Validación Técnica: Método del Codo

El análisis de la inercia muestra una disminución pronunciada en los primeros valores de k y posteriormente una reducción progresivamente menor, indicando que aumentar excesivamente la cantidad de grupos entrega mejoras marginales en la segmentación.




Figura 9: Validación técnica mediante Método del Codo

3.4. Visualización de Clústeres mediante PCA

Se utilizó PCA, Análisis de Componentes Principales, para representar visualmente en dos dimensiones la estructura del agrupamiento generado.

La visualización muestra la distribución de los vehículos en cuatro segmentos identificados por K-Means. Cada color representa un grupo con características similares considerando precio, kilometraje, año de fabricación, marca y modelo.

3.5. Perfilamiento de Clústeres

Clúster 1: Vehículos con mayor depreciación

Este segmento presenta el menor precio promedio, equivalente a \$11,6 millones, el mayor kilometraje promedio, equivalente a 140.042 km, y el año promedio más antiguo, correspondiente a 2016.

Corresponde principalmente a vehículos con mayor uso acumulado y antigüedad, lo que reduce significativamente su valor comercial. Representa el grupo con mayor depreciación dentro del mercado analizado.

Clúster 3: Vehículos de valor comercial intermedio

Este grupo presenta un precio promedio cercano a \$14,6 millones, un kilometraje promedio de 52.455 km y una antigüedad moderada, con año promedio 2022.

Se caracteriza por mantener un equilibrio entre uso, antigüedad y precio, agrupando vehículos recientes con depreciación controlada.

Clúster 2: Vehículos premium o de alto valor

Este segmento registra el mayor precio promedio, equivalente a \$41,8 millones, y uno de los menores kilometrajes promedio, equivalente a 42.266 km, junto con el año promedio más reciente, correspondiente a 2023.

Corresponde principalmente a vehículos de gama alta, modelos recientes y configuraciones que conservan mejor su valor dentro del mercado.

Clúster 0: Vehículos recientes con diversidad de marcas y modelos

Este grupo presenta un precio promedio de \$15,8 millones, kilometraje promedio de 64.660 km y año promedio 2021.

A diferencia de los demás segmentos, este clúster concentra una mayor diversidad de marcas y modelos, lo que indica que la incorporación de variables categóricas permitió capturar patrones más complejos que solo precio, kilometraje y antigüedad.

En conjunto, los resultados muestran que la depreciación no depende únicamente del uso del vehículo y su antigüedad, sino también de características asociadas a la identidad comercial del automóvil, particularmente la marca y el modelo, mejorando la capacidad explicativa de la segmentación obtenida mediante K-Means.



Figura 10: Perfilamiento de clústeres mediante PCA

3.6. Interpretación de Negocio

Los resultados obtenidos muestran que la depreciación de los vehículos usados no depende únicamente del kilometraje y del año de fabricación, sino también de atributos comerciales asociados al vehículo, especialmente la marca y el modelo.

Se identificó una relación consistente entre antigüedad, uso acumulado y valor comercial: los vehículos con mayor kilometraje y mayor antigüedad tienden a concentrarse en segmentos con menores precios promedio, evidenciando mayores niveles de depreciación.

Por otra parte, los segmentos con vehículos más recientes presentan menores niveles de desgaste y conservan una proporción superior de su valor comercial, especialmente cuando corresponden a determinadas marcas y modelos presentes en el mercado.

Desde una perspectiva de negocio, estos resultados permiten apoyar procesos de valorización de vehículos, estrategias de compra y venta, análisis de inventario y futuras etapas de predicción de depreciación y precio.

3.7. Interpretación de DBSCAN

DBSCAN fue utilizado como técnica complementaria para evaluar la estructura natural de los datos y detectar posibles observaciones atípicas dentro del mercado de vehículos usados. Los resultados obtenidos muestran la presencia de un clúster principal que concentra 1955 registros, acompañado por 30 observaciones clasificadas como ruido, cluster = -1, y un grupo secundario muy reducido de 3 registros.

Las observaciones identificadas como ruido corresponden a vehículos que presentan combinaciones poco frecuentes respecto al comportamiento general del conjunto de datos,

pudiendo asociarse a diferencias importantes en variables como precio, kilometraje, antigüedad, marca o modelo.

A diferencia de K-Means, DBSCAN no logró generar segmentos claramente diferenciados para representar perfiles comerciales del mercado, concentrando la mayoría de los vehículos en un único grupo dominante. Por esta razón, se decidió utilizar K-Means como algoritmo principal de segmentación, ya que entregó una separación más consistente entre grupos y una interpretación de negocio más clara.

Sin embargo, DBSCAN cumplió un rol importante como herramienta de validación, permitiendo confirmar que el conjunto de datos presenta una cantidad reducida de registros atípicos y una estructura general adecuada para el análisis.

Estos resultados respaldan que el conjunto de datos posee una estructura suficientemente estable para futuras etapas de análisis predictivo orientadas al estudio de depreciación y valorización de vehículos usados.




Figura 11: Visualización de resultados DBSCAN

3.8. Validación Técnica: Silhouette Score

Para complementar el Método del Codo se calculó el índice de Silhouette sobre distintas configuraciones del modelo K-Means utilizando las variables seleccionadas para el modelo final: precio, kilometraje, año de fabricación, marca y modelo.

Los resultados obtenidos fueron:

- k=2: 0.416
- k=3: 0.426
- k=4: 0.446
- k=5: 0.366

- k=6: 0.413
- k=7: 0.403

El mejor desempeño fue obtenido con $k=4$, alcanzando un Silhouette Score de 0.446.

Este valor indica una separación moderada entre clústeres y evidencia que el modelo logra identificar segmentos diferenciados dentro del mercado de vehículos usados. Aunque no representa una separación perfecta, sí demuestra una estructura consistente para interpretar distintos perfiles comerciales.

3.9. Relación con la Depreciación Vehicular

El objetivo principal del proyecto es analizar cómo distintas variables influyen en la depreciación de los vehículos usados, considerando factores asociados al uso del vehículo y características relacionadas con su posicionamiento dentro del mercado.

Los resultados obtenidos muestran una tendencia consistente: los vehículos con mayor antigüedad y mayor kilometraje tienden a presentar precios promedio más bajos, evidenciando una mayor depreciación acumulada.

Sin embargo, el análisis también evidencia que la depreciación no depende exclusivamente del desgaste y del paso del tiempo. Variables asociadas a la marca y al modelo aportan información adicional para explicar diferencias de valor entre vehículos con características de uso similares.

Por otra parte, los vehículos más recientes y con menor kilometraje presentan una mayor conservación de su valor comercial, especialmente cuando pertenecen a determinadas marcas y modelos que mantienen una valorización más estable dentro del mercado.

Estos hallazgos permiten concluir que la depreciación vehicular responde a una combinación de factores físicos y comerciales, justificando la incorporación de variables como precio, kilometraje, año, marca y modelo para futuras etapas de análisis predictivo y estimación de valor de mercado.

4. Definición Predictiva y Meta-Datos

4.1. Variable Dependiente (Y)

Para el desarrollo del Hito 3 se definió la variable precio como variable dependiente (Y), dado que representa el valor comercial de los vehículos usados y es uno de los principales elementos de interés para la toma de decisiones dentro del negocio automotriz.

La estimación del precio de los vehículos permite apoyar a los procesos de tasación, compra, venta, así también como la evaluación de vehículos, reemplazando criterios subjetivos por modelos basados en datos reales del mercado. Por esta razón, desarrollar un modelo predictivo basado en datos permite obtener estimaciones más precisas y respaldadas por información real del mercado automotriz.

Además, la variable precio corresponde a una variable cuantitativa continua, característica que la hace adecuada para la aplicación de técnicas de aprendizaje supervisado orientadas

a problemas de regresión. Su comportamiento está influenciado por distintos factores relacionados, lo que la convierte en una variable apropiada para ser utilizada como objetivo del modelo predictivo.

Durante el proceso de validación se realizó una limpieza de la variable, eliminando registros inconsistentes y valores fuera de rango. Como resultado, se identificaron registros válidos, aproximadamente al 54% del total de observaciones disponibles, lo que demuestra una alta disponibilidad y calidad de información para el proceso de modelamiento.

4.2. Factibilidad del Modelo Supervisado

Los resultados obtenidos permiten concluir que existe factibilidad técnica para desarrollar un modelo supervisado orientado a la predicción de precios de vehículos usados.

La base de datos procesada contiene más de 1988 registros válidos, distribuidos entre 60 marcas distintas y 70 ciudades diferentes aproximadamente, proporcionando una muestra amplia y representativa del mercado automotriz analizado. Esta diversidad favorece la capacidad del modelo para identificar patrones y relaciones presentes en distintos segmentos de vehículos. Asimismo, se identificaron variables explicativas con potencial predictivo, entre las que destacan.

Estas variables representan atributos que influyen directamente en la valoración comercial de un automóvil. Por ejemplo, vehículos con menor antigüedad suelen presentar precios más elevados, mientras que mayores niveles de kilometraje tienden a asociarse con una disminución de valor debido al desgaste acumulado. Del mismo modo, factores como la marca, el modelo y el tipo de combustible generan diferencias relevantes entre vehículos con características similares.

El análisis exploratorio realizado permitió observar relaciones entre estas variables y el precio, evidenciando que existe información suficiente para que un algoritmo de aprendizaje supervisado pueda identificar patrones y generar estimaciones confiables. Adicionalmente, la cantidad de observaciones disponibles reduce el riesgo de sobreajuste y favorece la capacidad de generalización de los modelos predictivos.

4.3. Selección del Modelo Predictivo

Para la etapa de aprendizaje supervisado se propone inicialmente el algoritmo Random Forest, debido a que presenta características adecuadas para el tipo de problema abordado en este proyecto. El objetivo consiste en estimar el precio de vehículos usados a partir de variables como el año, kilometraje, marca, modelo, combustible y ciudad, las cuales influyen de manera conjunta en el valor comercial de un automóvil.

La elección de Random Forest se fundamenta en su capacidad para trabajar con variables numéricas y categóricas, además de identificar relaciones complejas entre los datos sin requerir supuestos estrictos sobre su comportamiento. Esto resulta especialmente útil en el mercado automotriz, donde el precio de un vehículo depende de múltiples factores que interactúan entre sí.

Otra ventaja relevante de Random Forest es que reduce el riesgo de sobreajuste al combinar múltiples árboles de decisión, generando predicciones más estables y confiables que las

obtenidas mediante un único árbol. Por esta razón, se considera una alternativa adecuada para la estimación del precio de vehículos usados dentro del proyecto AutoTec.

En consecuencia, se propone Random Forest como el modelo supervisado principal para el desarrollo del Hito 3, utilizando el precio como variable dependiente y las características técnicas y comerciales de los vehículos como variables predictoras.

5. Conclusión

El proyecto abordó la problemática de la tasación de vehículos usados en el sector automotriz en Chile, reemplazando criterios subjetivos por un análisis sustentado en datos reales. A través de la limpieza de registros, la construcción de nuevas variables y la aplicación de técnicas de análisis exploratorio y de clustering, se logró identificar patrones consistentes de depreciación y segmentar el mercado en grupos diferenciados según características técnicas y comerciales.

Los resultados muestran que la depreciación de un vehículo usado no depende solo del kilometraje o de los años de fabricación. Esos factores son centrales, pero su impacto cambia según la marca y el modelo. Al incorporar estas variables categóricas fue posible capturar diferencias importantes en el valor comercial, lo que demuestra que autos con un nivel de uso parecido pueden tener precios muy distintos según cómo están posicionados en el mercado.

La aplicación de K-Means con $k=4$ entregó una estructura de segmentos clara y útil desde la perspectiva de negocio, mientras que DBSCAN cumplió un rol complementario en la detección de anomalías y validación de la estabilidad del conjunto de datos. En conjunto, estas técnicas confirmaron que el mercado automotriz usado puede representarse mediante perfiles diferenciados de depreciación y valor, aportando información clave para procesos de compra, venta e inventario.

Desde una perspectiva práctica, este trabajo aporta una herramienta concreta para la toma de decisiones en el sector automotriz. El análisis mejora la precisión de las tasaciones y reduce el riesgo de sobrevaloración o subvaloración. Además, los modelos aplicados representan el primer paso de AutoTec hacia la estimación de precios futuros y la anticipación de tendencias de mercado con mayor confianza.

En síntesis, el proyecto AutoTec demuestra que la integración de análisis de datos con técnicas como K-Means y DBSCAN nos permite entender mejor cómo se deprecian los vehículos usados. Gracias a estas herramientas pudimos identificar patrones, separar el mercado en segmentos con perfiles distintos y detectar casos atípicos que afectan las tasaciones. Todo esto convierte un proceso que antes dependía de la intuición en una base objetiva y confiable para tomar decisiones, estimar precios futuros y anticipar tendencias del mercado automotriz.

6. Anexo: Tabla de Aporte Individual

Cabe recalcar que la primera semana se distribuye a cada integrante una variable de las capturadas para que realice la limpieza, análisis e interpretación de los resultados. De esta

manera, cada variable es analizada de manera profunda. Esto se puede evidenciar en la rama de trabajo de cada estudiante.

A partir de la segunda semana se distribuyen las tareas mediante los roles propuestos por la guía de proyecto.

Cuadro 1: Tabla de aporte individual

Estudiante	Responsabilidad Técnica Específica	Rama de Trabajo	N° Com-mits
Belen Andrades	Semana 1: Limpieza, análisis y visualización de la variable marca. Semana 2: Desarrollo del informe de Análisis Descriptivo y adaptación de técnicas de clustering a los datos AutoTec. Semana 3: Construcción de correlaciones, análisis multivariado, heatmaps, scatterplots, boxplots y conclusiones EDA. Semana 4: Revisión y actualización del README, categorización de marcas y creación de la variable cat_marca.	belenandrades	4
Luz Azócar	Semana 1: Limpieza, análisis y visualización de la variable modelo. Semana 2: Desarrollo de análisis multivariado considerando combinaciones de variables relevantes para el negocio. Semana 3: Implementación técnica del análisis descriptivo, detección de anomalías y visualización de correlaciones. Semana 4: Incorporación de nuevas variables y actualización de análisis descriptivos.	Luz-azocar	10
Neiel Cortés	Semana 1: Limpieza, análisis y visualización de la variable combustible. Semana 2: Integración de datos, creación de variables derivadas y construcción de contenedores. Semana 3: Desarrollo de scraping adicional e integración de datos. Gestión de Infraestructura Cloud. Semana 4: Actualización de main.py, categorización de combustible y consolidación de tablas en README.	neiel-cortes	15
Daniela Cofré	Semana 1: Limpieza, análisis y visualización de la variable kilometraje. Semana 2: Implementación de K-Means, PCA, Método del Codo y Silhouette Score. Semana 3: Desarrollo completo del modelado no supervisado, validación técnica e interpretación de segmentos. Semana 4: Ajuste de clustering incorporando variables categorizadas cat_marca y cat_combustible.	Daniela-cofre	10
Jocelyn León	Semana 1: Limpieza, análisis y visualización de la variable year. Semana 2: EDA multivariado, precio vs año, precio vs kilometraje, segmentación y correlaciones. Semana 3: Interpretación de resultados EDA, análisis de anomalías y explicación de hallazgos para el informe. Semana 4: Elaboración del Anexo de Aporte Individual Auditable.	jocelyn-leon	15
Javiera Pizarro	Semana 1: Limpieza, análisis y visualización de la variable combustible. Semana 2: Definición de variable dependiente Y, metadatos y factibilidad predictiva. Semana 3: Justificación de la variable objetivo y análisis de algoritmos supervisados para etapas posteriores. Semana 4: Actualización de la propuesta predictiva y documentación de metadatos.	javiera-pizarro-cortes	13
Martin Rojas	Semana 1: Limpieza, análisis y visualización de la variable precio. Semana 2: Implementación y evaluación de DBSCAN. Semana 3: Elaboración de la documentación teórica del modelado no supervisado y apoyo a clustering. Semana 4: Redacción de conclusiones del informe y documentación de resultados obtenidos.	Martin-Rojas	13